Задачи по Эконометрике-1: Категориальные регрессоры и структурные сдвиги

Н. В. Артамонов, А. Н. Лата (МГИМО МИД России)

Содержание

1 Категориальные регрессоры **1**
1.1 diamond equation #1 . . . 1
1.2 diamond equation #2 . . . 4

2 Структурные сдвиги **6**
2.1 Рисунки: sleep по группам south . . . 6
2.2 sleep equation #1 . . . 6
2.3 sleep equation #2 . . . 7
2.4 wage equation #1 . . . 8
2.5 wage equation #2 . . . 9

! Важно

- Логарифм натуральный; константа включается в модель по умолчанию.
- Данные лежат в `datasets/`, описание переменных — в `datasets/data-description.md`.
- Ответы округляются до 2-х десятичных знаков, если в задаче не сказано иное; ответы считаются по неокруглённым оценкам.
- Коэффициенты подписаны так, как их печатает statsmodels: `Intercept` — константа, `np.log(x)` — $\log x$, `I(x ** 2)` — x^2, `x:d` — произведение `x` и `d`.
- `x[T.a]` — бинарная переменная для категории `a` категориального регрессора `x`. Например, `colour[T.E]` равна 1 для бриллиантов цвета E и 0 для остальных. У базовой категории своей строки нет; она названа в условии задачи.
- В таблицах раздела «Структурные сдвиги» в скобках — неробастные стандартные ошибки.

1 Категориальные регрессоры

1.1 diamond equation #1

Набор данных `Diamond`: `price` — цена, сингапурские доллары; `carat` — масса, караты; `colour` — цвет от D (лучший) до I; `clarity` — чистота; `certification` — организация, выдавшая сертификат (GIA, HRD, IGI).

Описательные статистики

Для набора данных `Diamond` вычислите описательные статистики количественных переменных (`df.describe()`) и число наблюдений по уровням категориальных регрессоров (`df['colour'].value_counts()`).

	carat	price
count	308	308
mean	0.6309	5019
std	0.2772	3403
min	0.1800	638
25%	0.3500	1625

	carat	price
50%	0.6200	4215
75%	0.8500	7446
max	1.1000	16008

	D	E	F	G	H	I
colour: число наблюдений	16	44	82	65	61	40

	IF	VS1	VS2	VVS1	VVS2
clarity: число наблюдений	44	81	53	52	78

	GIA	HRD	IGI
certification: число наблюдений	151	79	78

Регрессии

Для набора данных `Diamond` рассмотрим несколько линейных регрессий.

1. `np.log(price) ~ carat + I(carat**2) + colour`
2. `np.log(price) ~ carat + I(carat**2) + certification`
3. `np.log(price) ~ carat + I(carat**2) + colour + certification`

Базовые категории: `colour` — D, `certification` — GIA.

Оцените регрессии и дайте интерпретацию коэффициентам для категориальных регрессоров. Интерпретацию дайте в процентах: приближённо ($100 \cdot \beta$) и точно ($100 \cdot (e^{\beta} - 1)$). **Ответ округлите до 2-х десятичных знаков.**

Результаты оценивания

Модель 1

Переменная	Оценка
Intercept	5.98
colour[T.E]	-0.07
colour[T.F]	-0.14
colour[T.G]	-0.21
colour[T.H]	-0.30
colour[T.I]	-0.40
carat	5.40
I(carat ** 2)	-1.98

Модель была подогнана по 308 наблюдениям.

Модель 2

Переменная	Оценка
Intercept	5.69
certification[T.HRD]	0.03
certification[T.IGI]	0.07
carat	5.65

Переменная	Оценка
I(carat ** 2)	-2.19

Модель была подогнана по 308 наблюдениям.

Модель 3

Переменная	Оценка
Intercept	5.87
colour[T.E]	-0.08
colour[T.F]	-0.15
colour[T.G]	-0.23
colour[T.H]	-0.31
colour[T.I]	-0.41
certification[T.HRD]	0.04
certification[T.IGI]	0.09
carat	5.67
I(carat ** 2)	-2.15

Модель была подогнана по 308 наблюдениям.

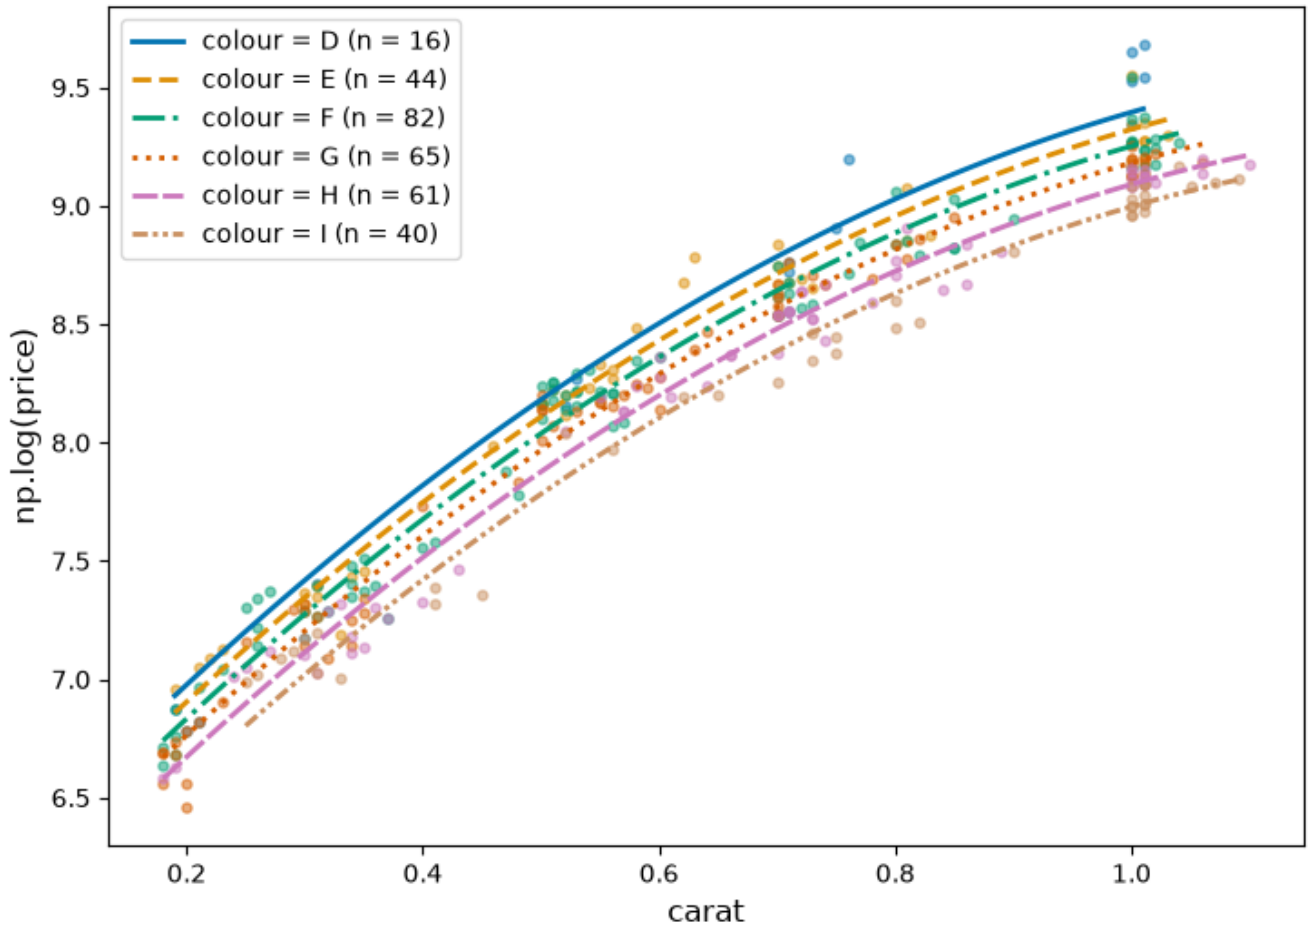


Рисунок 1: np.log(price) и carat по категориям colour (Diamond): категориальный регрессор сдвигает кривую параллельно

Ответ

Модель 1. Базовая категория — цвет D (лучший). При той же массе бриллиант дешевле бриллианта цвета D: E — на 7 % (7.0 %), F — на 14 % (13.3 %), G — на 21 % (19.2 %), H — на 30 % (26.3 %), I — на 40 % (32.9 %). Первое число — приближённая оценка $100 \cdot \beta$, в скобках — точная $100 \cdot (e^{\beta} - 1)$; чем больше $|\beta|$, тем сильнее они расходятся. Коэффициент при `colour[T.E]` — вертикальный сдвиг кривой относительно кривой цвета D (Рисунок 1).
Модель 2. Базовая категория — сертификат GIA. При той же массе бриллиант дороже бриллианта с сертификатом GIA: HRD — на 3 % (3.2 %), IGI — на 7 % (7.0 %).

1.2 diamond equation #2

Набор данных `diamonds`: `price` — цена, долл. США; `carat` — масса, караты; `cut` — качество огранки от Fair (худшее) до Ideal; `color` — цвет от D (лучший) до J; `clarity` — чистота; `x`, `y`, `z` — длина, ширина, высота в мм.

Описательные статистики

Для набора данных `diamonds` вычислите описательные статистики количественных переменных (`df.describe()`) и число наблюдений по уровням категориальных регрессоров (`df['cut'].value_counts()`).

Какие значения в таблице описательных статистик выглядят ошибочными? Сколько таких наблюдений?

	carat	depth	table	price	x	y	z
count	53940	53940	53940	53940	53940	53940	53940
mean	0.7979	61.75	57.46	3933	5.731	5.735	3.539
std	0.4740	1.43	2.23	3989	1.122	1.142	0.706
min	0.2000	43.00	43.00	326	0.000	0.000	0.000
25%	0.4000	61.00	56.00	950	4.710	4.720	2.910
50%	0.7000	61.80	57.00	2401	5.700	5.710	3.530
75%	1.0400	62.50	59.00	5324	6.540	6.540	4.040
max	5.0100	79.00	95.00	18823	10.740	58.900	31.800

	Fair	Good	Very Good	Premium	Ideal
cut: число наблюдений	1610	4906	12082	13791	21551

	D	E	F	G	H	I	J
color: число наблюдений	6775	9797	9542	11292	8304	5422	2808

	I1	SI2	SI1	VS2	VS1	VVS2	VVS1	IF
clarity: число наблюдений	741	9194	13065	12258	8171	5066	3655	1790

Ответ

Нулевые минимумы размеров `x`, `y`, `z` (число наблюдений с нулём: `x` — 8, `y` — 7, `z` — 20) и максимумы `y` = 58.9 мм, `z` = 31.8 мм при третьих квартилях 6.54 и 4.04 мм.

Регрессии

Для набора данных `diamonds` рассмотрим несколько линейных регрессий.

1. `np.log(price) ~ carat + I(carat**2) + cut + x + y + z`

2. `np.log(price) ~ carat + I(carat**2) + color + x + y + z`
3. `np.log(price) ~ carat + I(carat**2) + color + cut + x + y + z`

Базовые категории: `cut` — Fair, `color` — D.

Оцените регрессии и дайте интерпретацию коэффициентам для категориальных регрессоров. Интерпретацию дайте в процентах: приближённо ($100 \cdot \beta$) и точно ($100 \cdot (e^{\beta} - 1)$). **Ответ округлите до 2-х десятичных знаков.**

Результаты оценивания

Модель 1

Переменная	Оценка
Intercept	3.80
cut[T.Good]	0.12
cut[T.Very Good]	0.17
cut[T.Premium]	0.16
cut[T.Ideal]	0.24
carat	2.37
I(carat ** 2)	-0.64
x	0.38
y	0.02
z	0.06

Модель была подогнана по 53940 наблюдениям.

Модель 2

Переменная	Оценка
Intercept	4.08
color[T.E]	-0.03
color[T.F]	-0.04
color[T.G]	-0.07
color[T.H]	-0.21
color[T.I]	-0.30
color[T.J]	-0.43
carat	2.35
I(carat ** 2)	-0.61
x	0.38
y	0.03
z	0.05

Модель была подогнана по 53940 наблюдениям.

Модель 3

Переменная	Оценка
Intercept	3.99
color[T.E]	-0.03
color[T.F]	-0.04
color[T.G]	-0.07
color[T.H]	-0.21
color[T.I]	-0.31
color[T.J]	-0.43
cut[T.Good]	0.12
cut[T.Very Good]	0.18

Переменная	Оценка
cut[T.Premium]	0.16
cut[T.Ideal]	0.25
carat	2.54
I(carat ** 2)	-0.65
x	0.34
y	0.01
z	0.06

Модель была подогнана по 53940 наблюдениям.

Ответ

Модель 1. Базовая категория — огранка Fair (худшая). При тех же массе и размерах бриллиант дороже бриллианта с огранкой Fair: Good — на 12 % (12.3 %), Very Good — на 17 % (18.9 %), Premium — на 16 % (16.8 %), Ideal — на 24 % (27.7 %). Первое число — приближённая оценка $100 \cdot \beta$, в скобках — точная $100 \cdot (e^{\beta} - 1)$.
Модель 2. Базовая категория — цвет D (лучший). При тех же массе и размерах бриллиант дешевле бриллианта цвета D: E — на 3 % (3.1 %), F — на 4 % (3.9 %), G — на 7 % (6.5 %), H — на 21 % (18.9 %), I — на 30 % (26.2 %), J — на 43 % (35.2 %).

2 Структурные сдвиги

2.1 Рисунки: sleep по группам south

Набор данных `sleep75`: `sleep`, `totwrk` — сон и работа, минут в неделю; `age` — возраст, лет; `smsa` = 1 — живёт в крупной городской агломерации; `south` = 1 — южные штаты; `male` = 1 — мужчина.

Рисунок 2 — диаграмма рассеяния `sleep` и `totwrk` (набор данных `sleep75`) и три прямые МНК: по полной выборке, по наблюдениям с `south = 0` и с `south = 1`. Рисунок 3 — то же для регрессии **sleep на age, I(age**2)**.

Чем различаются прямые для `south = 0` и `south = 1` (Рисунок 2): сдвигом, наклоном или и тем и другим?

Почему линия полной выборки почти совпадает с линией `south = 0`?

Какими регрессорами нужно дополнить модель **sleep на totwrk**, чтобы одна регрессия дала обе прямые?

Ответ

Различается в основном наклон: -0.160 при `south = 0` и -0.101 при `south = 1`; константы близки (3586.7 и 3564.9). На группу `south = 0` приходится 576 наблюдений из 706, поэтому она определяет линию полной выборки. Модель нужно дополнить регрессорами `south` (сдвиг константы) и `totwrk:south` (сдвиг наклона).

2.2 sleep equation #1

Для набора данных `sleep75` рассмотрим регрессию **sleep на totwrk, age, smsa**: исходную (1) и со структурными сдвигами относительно бинарной переменной `male` (1 — мужчина) (2):

```
sleep ~ totwrk + age + smsa + male + totwrk:male + age:male + smsa:male
```

Результаты оценивания

	(1)	(2)
Dep. Variable	sleep	sleep
Intercept	3498.670	3486.973
	(69.133)	(92.418)
totwrk	-0.150***	-0.143***

	(1)	(2)
	(0.017)	(0.026)
age	2.997**	1.704
	(1.393)	(2.085)
smsa	-73.501**	-56.649
	(32.219)	(48.902)
male		135.200
		(143.832)
totwrk:male		-0.045
		(0.036)
age:male		1.500
		(2.825)
smsa:male		-34.735
		(64.938)
R-squared	0.115	0.126
R-squared Adj.	0.112	0.117
F Statistic	30.527***	14.387***
Observations	706	706
Residual Std. Error	418.877	417.530

Signif. codes: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$. В скобках — неробастные стандартные ошибки.

Для регрессии (2) выпишите оценённое уравнение отдельно для `male = 0` и для `male = 1`. Что показывают коэффициенты при `male` и при `age:male`? **Ответ округлите до 3-х десятичных знаков.**

Ответ

- `male = 0`: sleep = 3486.973 − 0.143·totwrk + 1.704·age − 56.649·smsa
- `male = 1`: sleep = 3622.172 − 0.188·totwrk + 3.204·age − 91.384·smsa

Коэффициент при `male` (135.200) — разность констант двух уравнений. Коэффициент при `age:male` (1.500) — разность коэффициентов при `age`: 3.204 при `male = 1` против 1.704 при `male = 0`. У мужчин дополнительный год возраста связан со сном, большим на 1.500 мин. в неделю, чем у женщин.

2.3 sleep equation #2

Для набора данных `sleep75` рассмотрим регрессию **sleep на totwrk, age, smsa**: исходную (1) и со структурными сдвигами относительно бинарной переменной `south` (1 — южные штаты) (2):

```
sleep ~ totwrk + age + smsa + south + totwrk:south + age:south + smsa:south
```

Результаты оценивания

	(1)	(2)
Dep. Variable	sleep	sleep
Intercept	3498.670	3557.513
	(69.133)	(75.504)
totwrk	-0.150***	-0.161***
	(0.017)	(0.018)
age	2.997**	1.485
	(1.393)	(1.545)
smsa	-73.501**	-61.554*
	(32.219)	(34.856)
south		-407.206**
		(189.627)
totwrk:south		0.078

	(1)	(2)
		(0.050)
age:south		8.267**
		(3.495)
smsa:south		49.429
		(107.111)
R-squared	0.115	0.131
R-squared Adj.	0.112	0.122
F Statistic	30.527***	15.039***
Observations	706	706
Residual Std. Error	418.877	416.341

Signif. codes: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$. В скобках — необастные стандартные ошибки.

Для регрессии (2) выпишите оценённое уравнение отдельно для `south = 0` и для `south = 1`. Что показывают коэффициенты при `south` и при `age:south`? **Ответ округлите до 3-х десятичных знаков.**

Ответ

- `south = 0`: sleep = 3557.513 − 0.161·totwrk + 1.485·age − 61.554·smsa
- `south = 1`: sleep = 3150.307 − 0.082·totwrk + 9.752·age − 12.125·smsa

Коэффициент при `south` (-407.206) — разность констант двух уравнений. Коэффициент при `age:south` (8.267) — разность коэффициентов при `age`: 9.752 при `south = 1` против 1.485 при `south = 0`. На Юге дополнительный год возраста связан со сном, большим на 8.267 мин. в неделю, чем вне Юга.

2.4 wage equation #1

Набор данных `wage2`: `wage` — месячная зарплата, долл.; `age` — возраст, лет; `IQ` — результат теста IQ; `urban` = 1 — живёт в городе; `married` = 1 — в браке; `south` = 1 — южные штаты.

Для набора данных `wage2` рассмотрим регрессию **np.log(wage) на age, IQ, urban, married**: исходную (1) и со структурными сдвигами относительно бинарной переменной `south` (1 — южные штаты) (2):

```
np.log(wage) ~ age + IQ + urban + married + south +
    age:south + IQ:south + urban:south + married:south
```

Результаты оценивания

	(1)	(2)
Dep. Variable	np.log(wage)	np.log(wage)
Intercept	4.849	4.914
	(0.163)	(0.204)
age	0.022***	0.024***
	(0.004)	(0.005)
IQ	0.009***	0.008***
	(0.001)	(0.001)
urban	0.186***	0.217***
	(0.028)	(0.035)
married	0.198***	0.201***
	(0.041)	(0.049)
south		-0.011
		(0.348)
age:south		-0.007
		(0.009)
IQ:south		0.002
		(0.002)

	(1)	(2)
urban:south		-0.114**
		(0.057)
married:south		-0.003
		(0.087)
R-squared	0.188	0.205
R-squared Adj.	0.184	0.197
F Statistic	53.799***	26.481***
Observations	935	935
Residual Std. Error	0.380	0.377

Signif. codes: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$. В скобках — неробастные стандартные ошибки.

Для регрессии (2) выпишите оценённое уравнение отдельно для `south = 0` и для `south = 1`. Что показывают коэффициенты при `south` и при `urban:south`? **Ответ округлите до 3-х десятичных знаков.**

Ответ

- `south = 0`: np.log(wage) = 4.914 + 0.024·age + 0.008·IQ + 0.217·urban + 0.201·married
- `south = 1`: np.log(wage) = 4.903 + 0.017·age + 0.010·IQ + 0.103·urban + 0.198·married

Коэффициент при `south` (-0.011) — разность констант двух уравнений. Коэффициент при `urban:south` (-0.114) — разность коэффициентов при `urban`: 0.103 при `south = 1` против 0.217 при `south = 0`. Зависимая переменная — логарифм, поэтому разность читается в процентных пунктах: на Юге надбавка за жизнь в городе приближённо на 11.4 п. п. меньше (10.3 % против 21.7 %).

2.5 wage equation #2

Для набора данных `wage2` рассмотрим регрессию **np.log(wage) на age, IQ, south**: исходную (1) и со структурными сдвигами относительно бинарной переменной `urban` (1 — живёт в городе) (2):

```
np.log(wage) ~ age + IQ + south + urban + age:urban + IQ:urban + south:urban
```

Результаты оценивания

	(1)	(2)
Dep. Variable	np.log(wage)	np.log(wage)
Intercept	5.214	4.999
	(0.168)	(0.312)
age	0.023***	0.024***
	(0.004)	(0.007)
IQ	0.008***	0.008***
	(0.001)	(0.002)
south	-0.113***	-0.014
	(0.028)	(0.052)
urban		0.237
		(0.368)
age:urban		-0.001
		(0.009)
IQ:urban		-1.41e-05
		(0.002)
south:urban		-0.117*
		(0.061)
R-squared	0.146	0.182
R-squared Adj.	0.143	0.176
F Statistic	52.872***	29.417***

	(1)	(2)
Observations	935	935
Residual Std. Error	0.390	0.382

Signif. codes: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$. В скобках — неробастные стандартные ошибки.

Для регрессии (2) выпишите оценённое уравнение отдельно для `urban = 0` и для `urban = 1`. Что показывают коэффициенты при `urban` и при `south:urban`? **Ответ округлите до 3-х десятичных знаков.**

Ответ

- `urban = 0`: np.log(wage) = 4.999 + 0.024·age + 0.008·IQ − 0.014·south
- `urban = 1`: np.log(wage) = 5.235 + 0.024·age + 0.008·IQ − 0.131·south

Коэффициент при `urban` (0.237) — разность констант двух уравнений. Коэффициент при `south:urban` (-0.117) — разность коэффициентов при `south`: -0.131 при `urban = 1` против -0.014 при `urban = 0`. Зависимая переменная — логарифм, поэтому разность читается в процентных пунктах: в городе отставание зарплаты на Юге приближённо на 11.7 п. п. больше (13.1 % против 1.4 %).

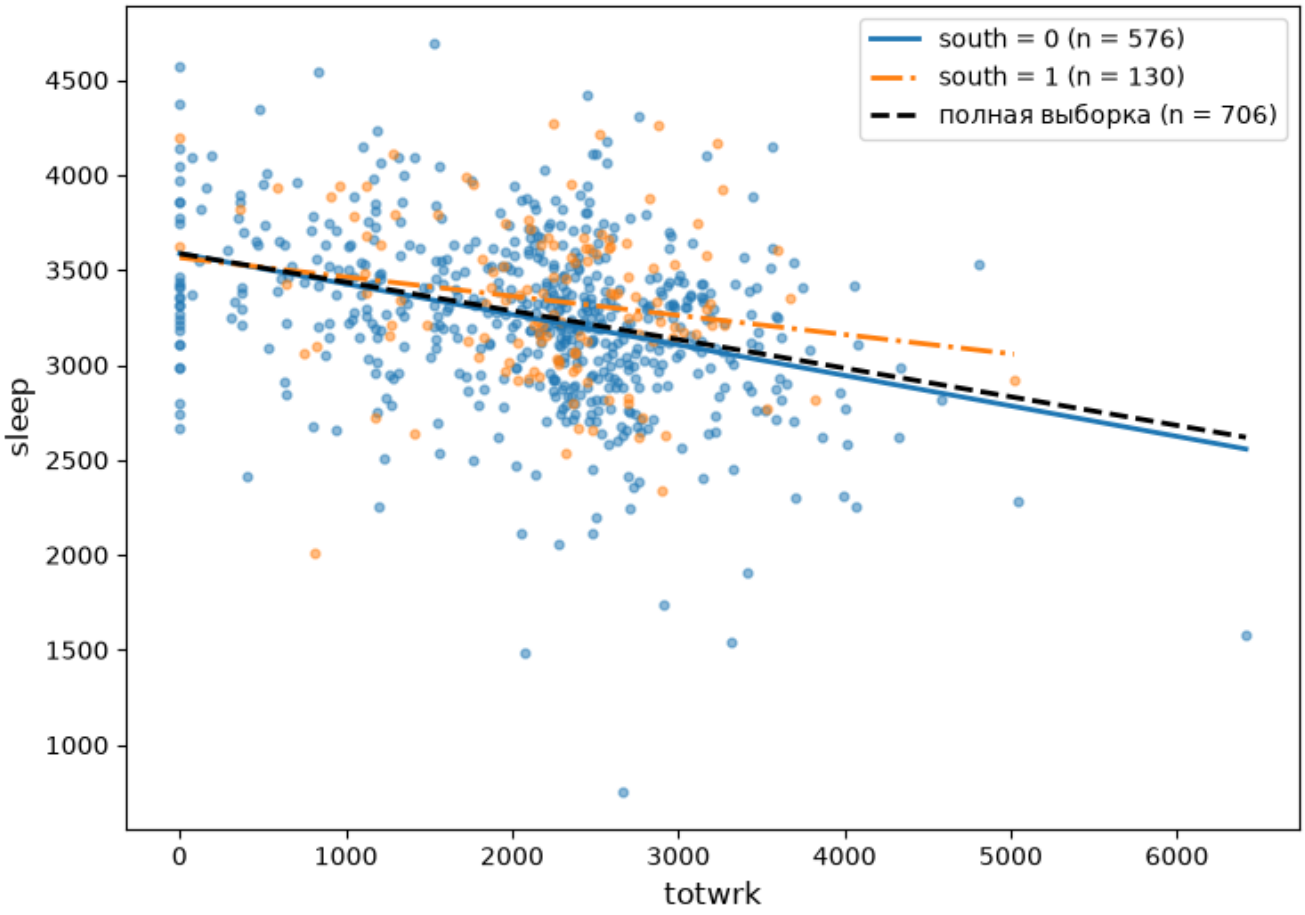


Рисунок 2: sleep на totwrk: подгонка по полной выборке и отдельно для south = 0 и south = 1

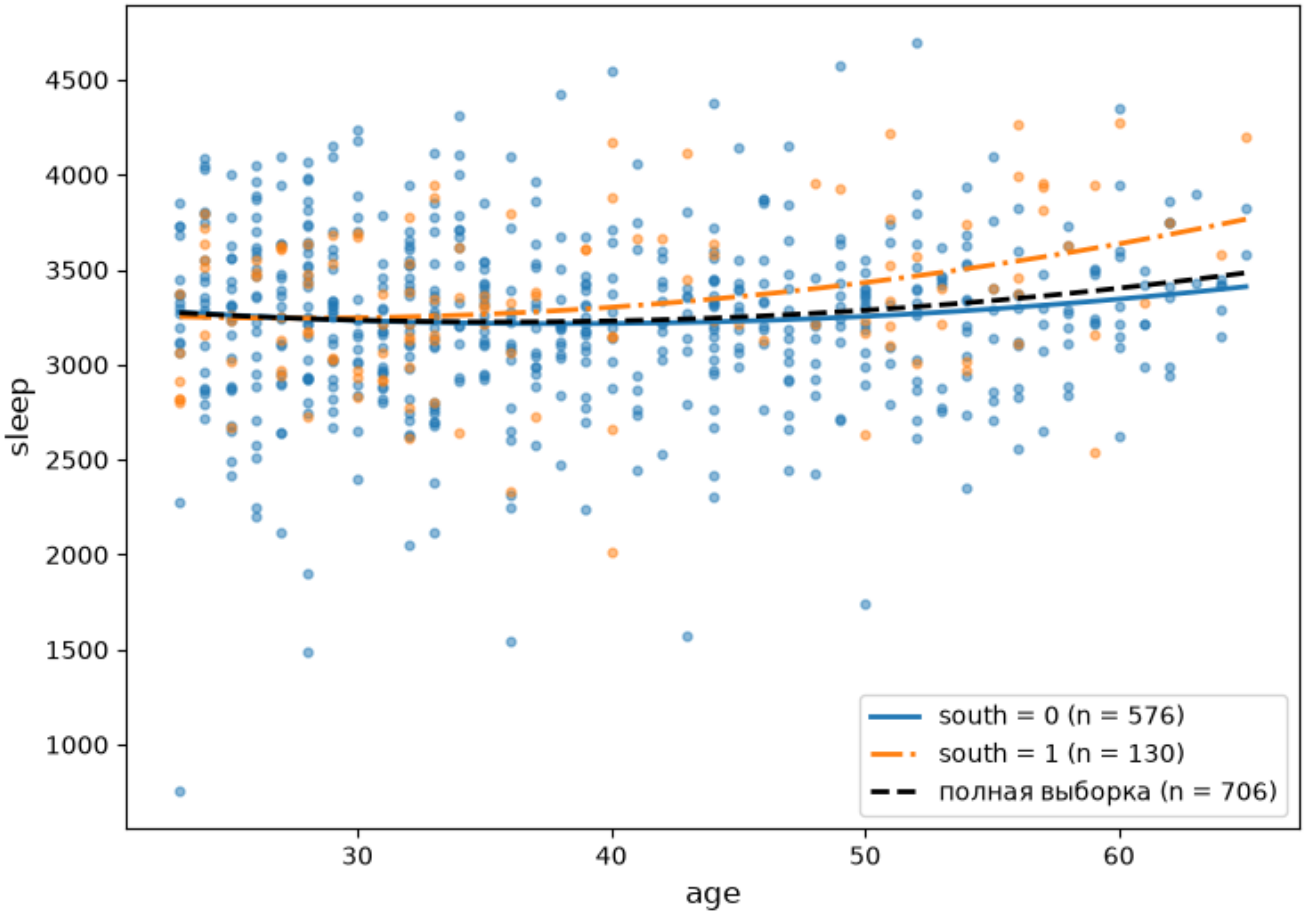


Рисунок 3: sleep на age, I(age**2): подгонка по полной выборке и отдельно для south = 0 и south = 1