Задачи по Эконометрике-1: Мультиколлинеарность

Н. В. Артамонов, А. Н. Лата (МГИМО МИД России)

Содержание

1 Мультиколлинеарность: VIF, t-тест и F-тест **1**
1.1 sleep equation #1 . . . 1
1.2 sleep equation #2 . . . 3
1.3 sleep equation #3 . . . 5
1.4 wage equation #1 . . . 8
1.5 wage equation #2 . . . 10

! Важно

- Логарифм натуральный; константа включается в модель по умолчанию.
- Данные — в папке `datasets/`, описание переменных — в `datasets/data-description.md`.
- VIF и критические значения округляются до 2-х десятичных знаков, остальные ответы — до 3-х. Ответы считаются по неокруглённым оценкам.
- Коэффициенты подписаны как в statsmodels: `Intercept` — константа, `np.log(x)` — $\log x$, `I(x ** 2)` — x^2, `I(x * d)` — произведение $x \cdot d$.
- Все тесты в этом листке — с **необастными** стандартными ошибками; критические значения и P-значения — по t- и F-распределениям.

1 Мультиколлинеарность: VIF, t-тест и F-тест

1.1 sleep equation #1

Для набора данных `sleep75` рассмотрим регрессию

```
sleep ~ I(totwrk/100) + I(totwrk**2/10000) + age + smsa + male
```

Переменные `sleep` (сон) и `totwrk` (занятость) измерены в минутах в неделю, `age` — в годах; `smsa`, `male`, `union`, `south` — бинарные переменные.

Модель была подогнана по 706 наблюдениям.

Вычислите показатели VIF для регрессоров. **Ответ округлите до 2-х десятичных знаков.**

Переменная	VIF
I(totwrk / 100)	8.37
I(totwrk ** 2 / 10000)	8.20
age	1.01
smsa	1.00
male	1.17

Вычислите корреляционную матрицу регрессоров. **Ответ округлите до 3-х десятичных знаков.**

	I(totwrk / 100)	I(totwrk ** 2 / 10000)	age	smsa	male
I(totwrk / 100)	1.000	0.937	-0.050	-0.038	0.376
I(totwrk ** 2 / 10000)	0.937	1.000	-0.046	-0.051	0.351
age	-0.050	-0.046	1.000	0.025	0.032
smsa	-0.038	-0.051	0.025	1.000	0.007
male	0.376	0.351	0.032	0.007	1.000

Постройте тепловую карту корреляционной матрицы (Рисунок 1).

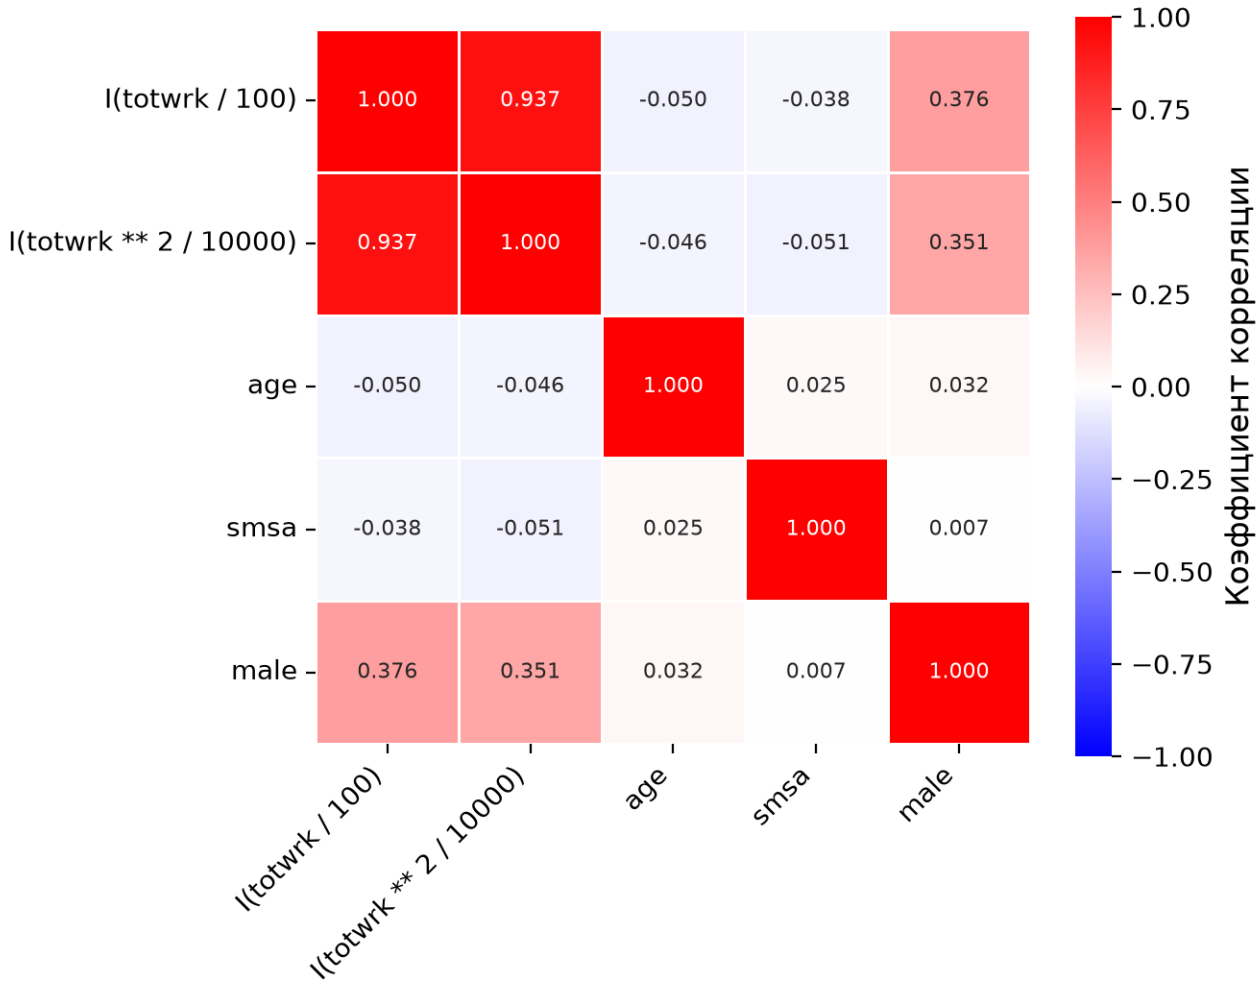


Рисунок 1: Корреляционная матрица регрессоров (sleep equation #1)

> **!** Условия теста
>
> - уровень значимости: **5%**
> - стандартные ошибки: **неробастные**
> - гипотеза 1: t-тест, значимость каждого коэффициента: $H_0 : \beta_j = 0$
> - гипотеза 2: F-тест, значимость влияния занятости: $H_0 : \beta_{totwrk/100} = \beta_{totwrk^2/10000} = 0$

Какие коэффициенты значимы?

Результаты t-теста для коэффициентов (неробастные стандартные ошибки):

	Coef.	Std.Err.	t-value	p-value	Signif.
Intercept	3428.805	76.655	44.730	<0.001	
I(totwrk / 100)	-8.195	4.789	-1.711	0.088	*
I(totwrk ** 2 / 10000)	-0.214	0.111	-1.930	0.054	*
age	2.817	1.387	2.031	0.043	**
smsa	-78.049	32.072	-2.434	0.015	**
male	86.639	34.200	2.533	0.012	**

Signif. codes: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$

Коэффициенты, значимые на уровне 5% (по необастным стандартным ошибкам)

`age`, `smsa`, `male`

Проверим гипотезу о значимости влияния занятости.

Результаты F-теста (необастные стандартные ошибки):

F	df1	df2	p-value
45.619	2	700	<0.001

Вычислите критическое значение. **Ответ округлите до 2-х десятичных знаков.**

Критическое значение

$F_{crit} = 3.01$

Какой можно сделать вывод?

Вывод

$F = 45.619 > 3.01$, гипотеза H_0 отвергается.
На первый взгляд противоречие: коэффициенты при `I(totwrk / 100)` и `I(totwrk ** 2 / 10000)` по отдельности незначимы (P-значения 0.088 и 0.054), а гипотеза об их совместной незначимости отвергается. Оно объясняется мультиколлинеарностью: корреляция двух регрессоров равна 0.937, VIF — 8.37 и 8.20.

1.2 sleep equation #2

Для набора данных `sleep75` рассмотрим регрессию

```
sleep ~ totwrk + age + I(age**2) + smsa + male + union
```

Модель была подогнана по 706 наблюдениям.

Вычислите показатели VIF для регрессоров. **Ответ округлите до 2-х десятичных знаков.**

Переменная	VIF
totwrk	1.20
age	65.40
I(age ** 2)	65.56
smsa	1.00
male	1.17
union	1.01

Вычислите корреляционную матрицу регрессоров. **Ответ округлите до 3-х десятичных знаков.**

	totwrk	age	I(age ** 2)	smsa	male	union
totwrk	1.000	-0.050	-0.067	-0.038	0.376	0.002
age	-0.050	1.000	0.992	0.025	0.032	-0.037
I(age ** 2)	-0.067	0.992	1.000	0.024	0.026	-0.042
smsa	-0.038	0.025	0.024	1.000	0.007	-0.039
male	0.376	0.032	0.026	0.007	1.000	0.040
union	0.002	-0.037	-0.042	-0.039	0.040	1.000

Постройте тепловую карту корреляционной матрицы (Рисунок 2).

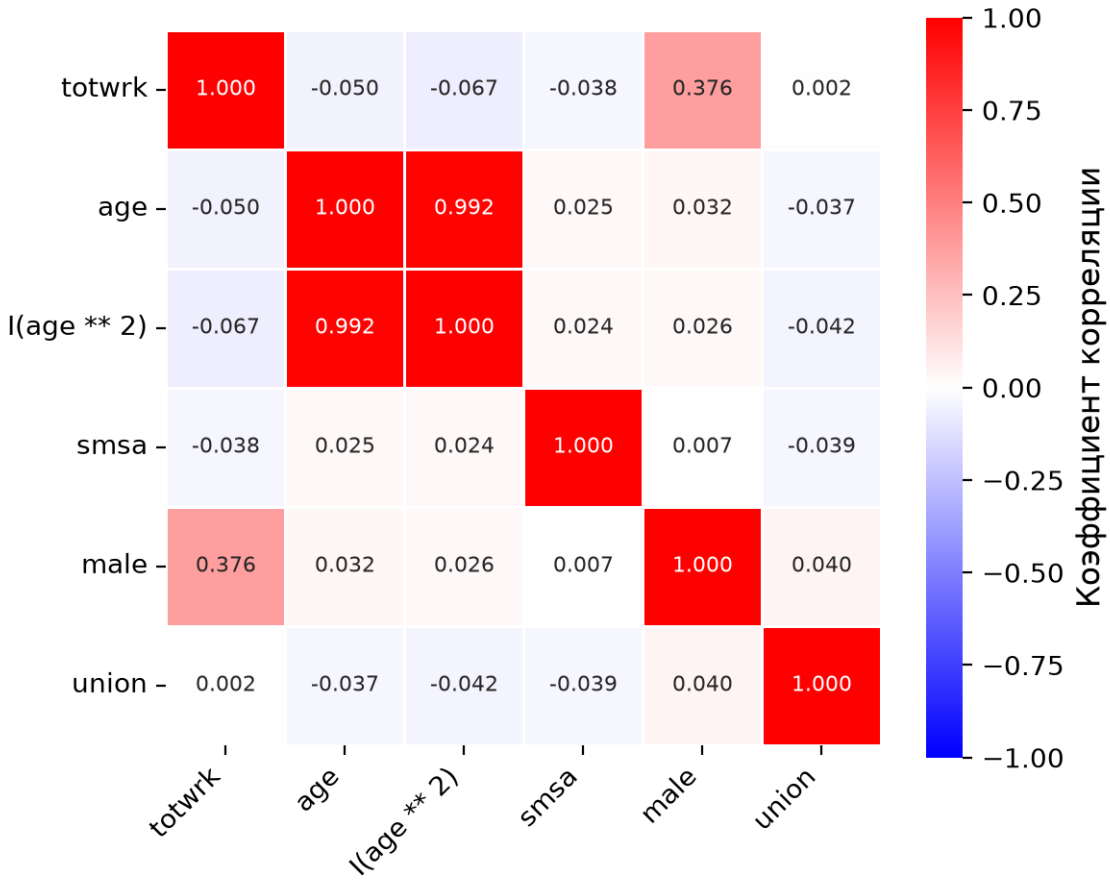


Рисунок 2: Корреляционная матрица регрессоров (sleep equation #2)

> ! Условия теста
>
> - уровень значимости: **5% и 10%**
> - стандартные ошибки: **неробастные**
> - гипотеза 1: t-тест, значимость каждого коэффициента: $H_0 : \beta_j = 0$
> - гипотеза 2: F-тест, значимость влияния возраста: $H_0 : \beta_{age} = \beta_{age^2} = 0$

Какие коэффициенты значимы на каждом из двух уровней?

Результаты t-теста для коэффициентов (неробастные стандартные ошибки):

	Coef.	Std.Err.	t-value	p-value	Signif.
Intercept	3688.551	218.389	16.890	<0.001	
totwrk	-0.165	0.018	-9.105	<0.001	***
age	-7.734	11.213	-0.690	0.491	
I(age ** 2)	0.127	0.134	0.948	0.343	
smsa	-74.527	32.156	-2.318	0.021	**
male	86.321	34.329	2.515	0.012	**
union	8.574	38.195	0.224	0.822	

Signif. codes: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$

Значимые коэффициенты (по необастным стандартным ошибкам)

- на уровне 5%: `totwrk`, `smsa`, `male`
- на уровне 10%: `totwrk`, `smsa`, `male`

Проверим гипотезу о значимости влияния возраста.

Результаты F-теста (необастные стандартные ошибки):

F	df1	df2	p-value
2.497	2	699	0.083

Вычислите критические значения для двух уровней значимости. **Ответ округлите до 2-х десятичных знаков.**

Критические значения

- уровень значимости 5%: $F_{crit} = 3.01$
- уровень значимости 10%: $F_{crit} = 2.31$

Какой можно сделать вывод на каждом из двух уровней?

Вывод

- На уровне 5%: $F = 2.497 < 3.01$, гипотеза H_0 не отвергается. Противоречия нет: коэффициенты при `age` и `I(age ** 2)` незначимы по отдельности (P-значения 0.491 и 0.343), и гипотеза об их совместной незначимости тоже не отвергается.
- На уровне 10%: $F = 2.497 > 2.31$, гипотеза H_0 отвергается, хотя коэффициенты при `age` и `I(age ** 2)` по отдельности незначимы. **На первый взгляд противоречие.** Оно объясняется мультиколлинеарностью: корреляция `age` и `I(age ** 2)` равна 0.992, VIF — 65.40 и 65.56.

1.3 sleep equation #3

Для набора данных `sleep75` рассмотрим регрессию

```
sleep ~ totwrk + age + smsa + south +
        I(totwrk*south) + I(age*south) + I(smsa*south)
```

Модель была подогнана по 706 наблюдениям.

Вычислите показатели VIF для регрессоров. **Ответ округлите до 2-х десятичных знаков.**

Переменная	VIF
totwrk	1.15

Переменная	VIF
age	1.25
smsa	1.19
south	22.00
I(totwrk * south)	8.85
I(age * south)	12.28
I(smsa * south)	1.29

Вычислите корреляционную матрицу регрессоров. **Ответ округлите до 3-х десятичных знаков.**

	totwrk	age	smsa	south	I(totwrk * south)	I(age * south)	I(smsa * south)
totwrk	1.000	-0.050	-0.038	0.051	0.175	0.033	0.012
age	-0.050	1.000	0.025	-0.018	-0.038	0.126	0.008
smsa	-0.038	0.025	1.000	-0.238	-0.224	-0.222	0.209
south	0.051	-0.018	-0.238	1.000	0.932	0.947	0.359
I(totwrk * south)	0.175	-0.038	-0.224	0.932	1.000	0.868	0.328
I(age * south)	0.033	0.126	-0.222	0.947	0.868	1.000	0.351
I(smsa * south)	0.012	0.008	0.209	0.359	0.328	0.351	1.000

Постройте тепловую карту корреляционной матрицы (Рисунок 3).

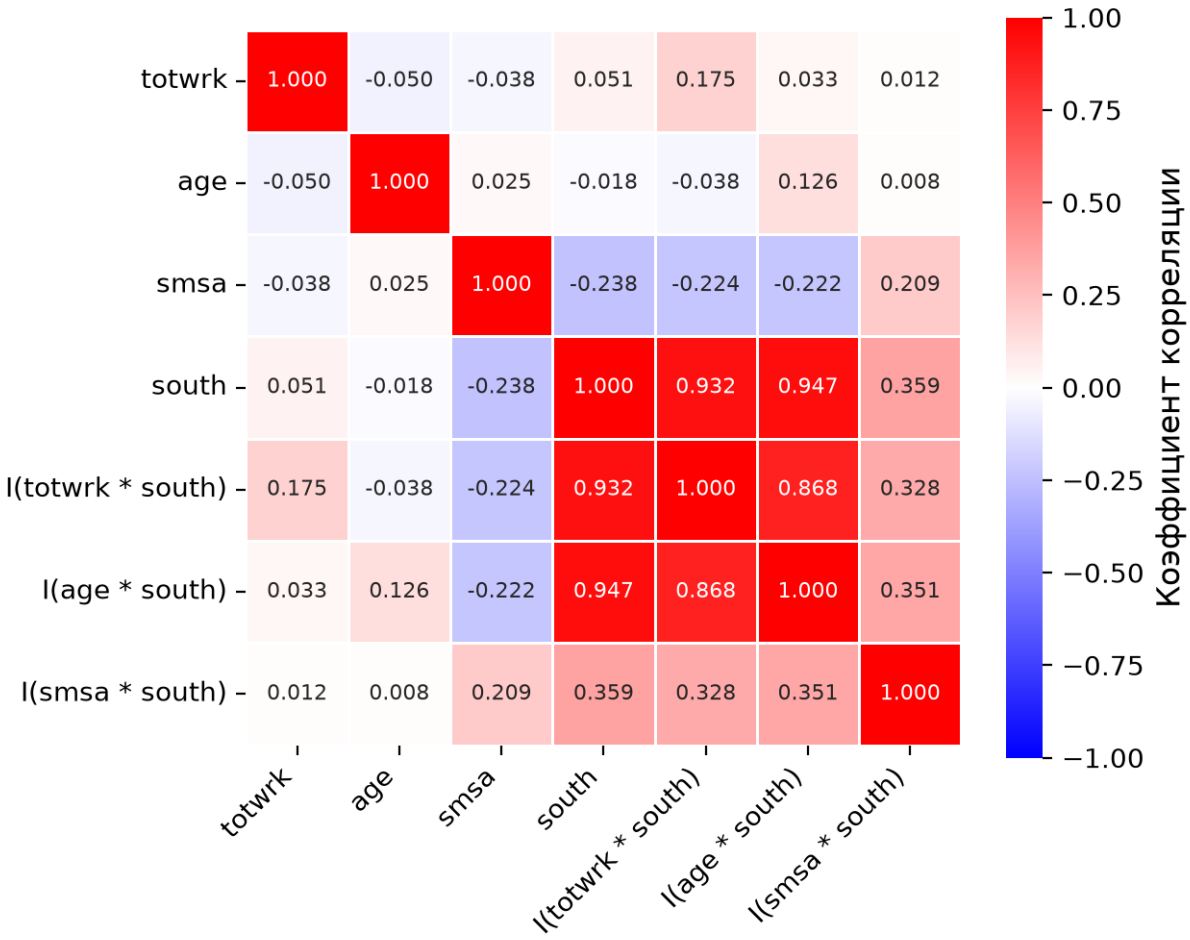


Рисунок 3: Корреляционная матрица регрессоров (sleep equation #3)

! Условия теста

- уровень значимости: **5%**
- стандартные ошибки: **неробастные**
- гипотеза 1: t-тест, значимость каждого коэффициента: $H_0 : \beta_j = 0$
- гипотеза 2: F-тест, значимость региона (переменная `south`): $H_0 : \beta_{south} = \beta_{totwrk \cdot south} = \beta_{age \cdot south} = \beta_{smsa \cdot south} = 0$

Какие коэффициенты значимы?

Результаты t-теста для коэффициентов (неробастные стандартные ошибки):

	Coef.	Std.Err.	t-value	p-value	Signif.
Intercept	3557.513	75.504	47.117	<0.001	
totwrk	-0.161	0.018	-9.062	<0.001	***
age	1.485	1.545	0.961	0.337	
smsa	-61.554	34.856	-1.766	0.078	*
south	-407.206	189.627	-2.147	0.032	**
I(totwrk * south)	0.078	0.050	1.556	0.120	
I(age * south)	8.267	3.495	2.365	0.018	**
I(smsa * south)	49.429	107.111	0.461	0.645	

Signif. codes: $*** \; p < 0.01$, $** \; p < 0.05$, $* \; p < 0.1$

i Коэффициенты, значимые на уровне 5% (по неробастным стандартным ошибкам)

`totwrk`, `south`, `I(age * south)`

Проверим гипотезу о значимости региона.

Результаты F-теста (неробастные стандартные ошибки):

F	df1	df2	p-value
3.144	4	698	0.014

Вычислите критическое значение. **Ответ округлите до 2-х десятичных знаков.**

i Критическое значение

$F_{crit} = 2.38$

Какой можно сделать вывод?

Вывод

$F = 3.144 > 2.38$, гипотеза H_0 отвергается.
Здесь противоречия нет: коэффициенты при `south` и `I(age * south)` значимы и по отдельности (P-значения 0.032 и 0.018), а F-тест отвергает совместную незначимость всех четырёх. При этом VIF у `south` равен 22.00, у `I(age * south)` — 12.28: высокий VIF увеличивает стандартные ошибки, но сам по себе не делает коэффициент незначимым.

1.4 wage equation #1

Для набора данных `wage2` рассмотрим регрессию

```
np.log(wage) ~ age + I(age**2) + IQ + married + south + urban
```

Переменная `wage` — месячный заработок, `age` — возраст в годах, `IQ` — результат теста IQ; `married`, `south`, `urban` — бинарные переменные.

Модель была подогнана по 935 наблюдениям.

Вычислите показатели VIF для регрессоров. **Ответ округлите до 2-х десятичных знаков.**

Переменная	VIF
age	632.87
I(age ** 2)	632.96
IQ	1.05
married	1.01
south	1.06
urban	1.02

Вычислите корреляционную матрицу регрессоров. **Ответ округлите до 3-х десятичных знаков.**

	age	I(age ** 2)	IQ	married	south	urban
age	1.000	0.999	-0.044	0.107	-0.029	-0.007
I(age ** 2)	0.999	1.000	-0.043	0.107	-0.031	-0.009
IQ	-0.044	-0.043	1.000	-0.015	-0.210	0.039
married	0.107	0.107	-0.015	1.000	0.023	-0.040
south	-0.029	-0.031	-0.210	0.023	1.000	-0.110
urban	-0.007	-0.009	0.039	-0.040	-0.110	1.000

Постройте тепловую карту корреляционной матрицы (Рисунок 4).

> ! Условия теста
>
> - уровень значимости: **5%**
> - стандартные ошибки: **необастные**
> - гипотеза 1: t-тест, значимость каждого коэффициента: $H_0 : \beta_j = 0$
> - гипотеза 2: F-тест, значимость влияния возраста: $H_0 : \beta_{age} = \beta_{age^2} = 0$

Какие коэффициенты значимы?

Результаты t-теста для коэффициентов (необастные стандартные ошибки):

	Coef.	Std.Err.	t-value	p-value	Signif.
Intercept	2.938	1.656	1.774	0.076	
age	0.145	0.100	1.447	0.148	
I(age ** 2)	-0.002	0.002	-1.236	0.217	
IQ	0.008	0.001	9.770	<0.001	***
married	0.202	0.040	5.008	<0.001	***
south	-0.100	0.027	-3.736	<0.001	***
urban	0.173	0.028	6.260	<0.001	***

Signif. codes: $*** \; p < 0.01$, $** \; p < 0.05$, $* \; p < 0.1$

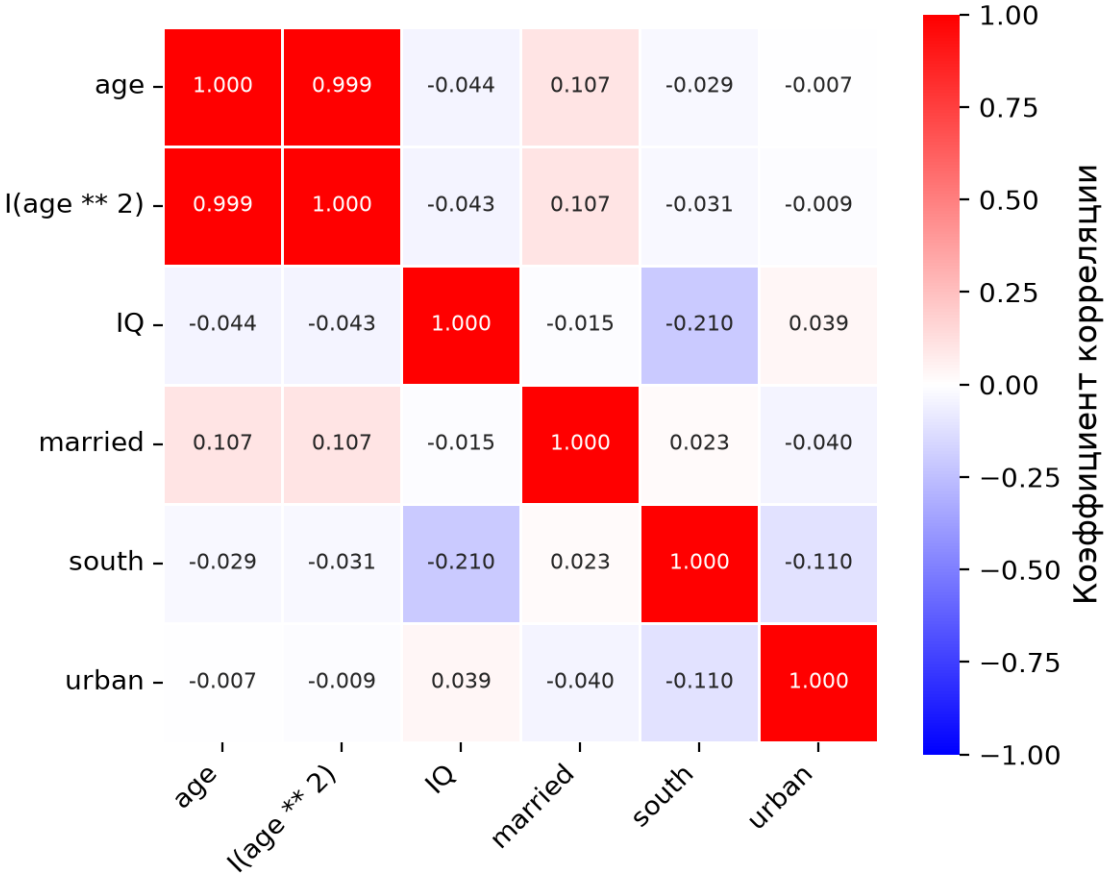


Рисунок 4: Корреляционная матрица регрессоров (wage equation #1)

Коэффициенты, значимые на уровне 5% (по необастным стандартным ошибкам)

`IQ`, `married`, `south`, `urban`

Проверим гипотезу о значимости влияния возраста.

Результаты F-теста (необастные стандартные ошибки):

F	df1	df2	p-value
14.833	2	928	<0.001

Вычислите критическое значение. **Ответ округлите до 2-х десятичных знаков.**

Критическое значение

$F_{crit} = 3.01$

Какой можно сделать вывод?

Вывод

$F = 14.833 > 3.01$, гипотеза H_0 отвергается.
На первый взгляд противоречие: коэффициенты при `age` и `I(age ** 2)` по отдельности незначимы (P-значения 0.148 и 0.217), а гипотеза об их совместной незначимости отвергается. Оно объясняется мультиколлинеарностью: корреляция `age` и `I(age ** 2)` равна 0.999, VIF — 632.87 и 632.96.

1.5 wage equation #2

Для набора данных `wage2` рассмотрим регрессию

```
np.log(wage) ~ age + IQ + south + urban +
               I(age*urban) + I(IQ*urban) + I(south*urban)
```

Модель была подогнана по 935 наблюдениям.

Вычислите показатели VIF для регрессоров. **Ответ округлите до 2-х десятичных знаков.**

Переменная	VIF
age	3.39
IQ	3.88
south	3.83
urban	175.88
I(age * urban)	114.32
I(IQ * urban)	53.14
I(south * urban)	4.09

Вычислите корреляционную матрицу регрессоров. **Ответ округлите до 3-х десятичных знаков.**

	age	IQ	south	urban	I(age * urban)	I(IQ * urban)	I(south * urban)
age	1.000	-0.044	-0.029	-0.007	0.137	-0.020	0.010
IQ	-0.044	1.000	-0.210	0.039	0.030	0.260	-0.097
south	-0.029	-0.210	1.000	-0.110	-0.106	-0.136	0.741
urban	-0.007	0.039	-0.110	1.000	0.985	0.964	0.334

	age	IQ	south	urban	I(age * urban)	I(IQ * urban)	I(south * urban)
I(age * urban)	0.137	0.030	-0.106	0.985	1.000	0.947	0.332
I(IQ * urban)	-0.020	0.260	-0.136	0.964	0.947	1.000	0.288
I(south * urban)	0.010	-0.097	0.741	0.334	0.332	0.288	1.000

Постройте тепловую карту корреляционной матрицы (Рисунок 5).

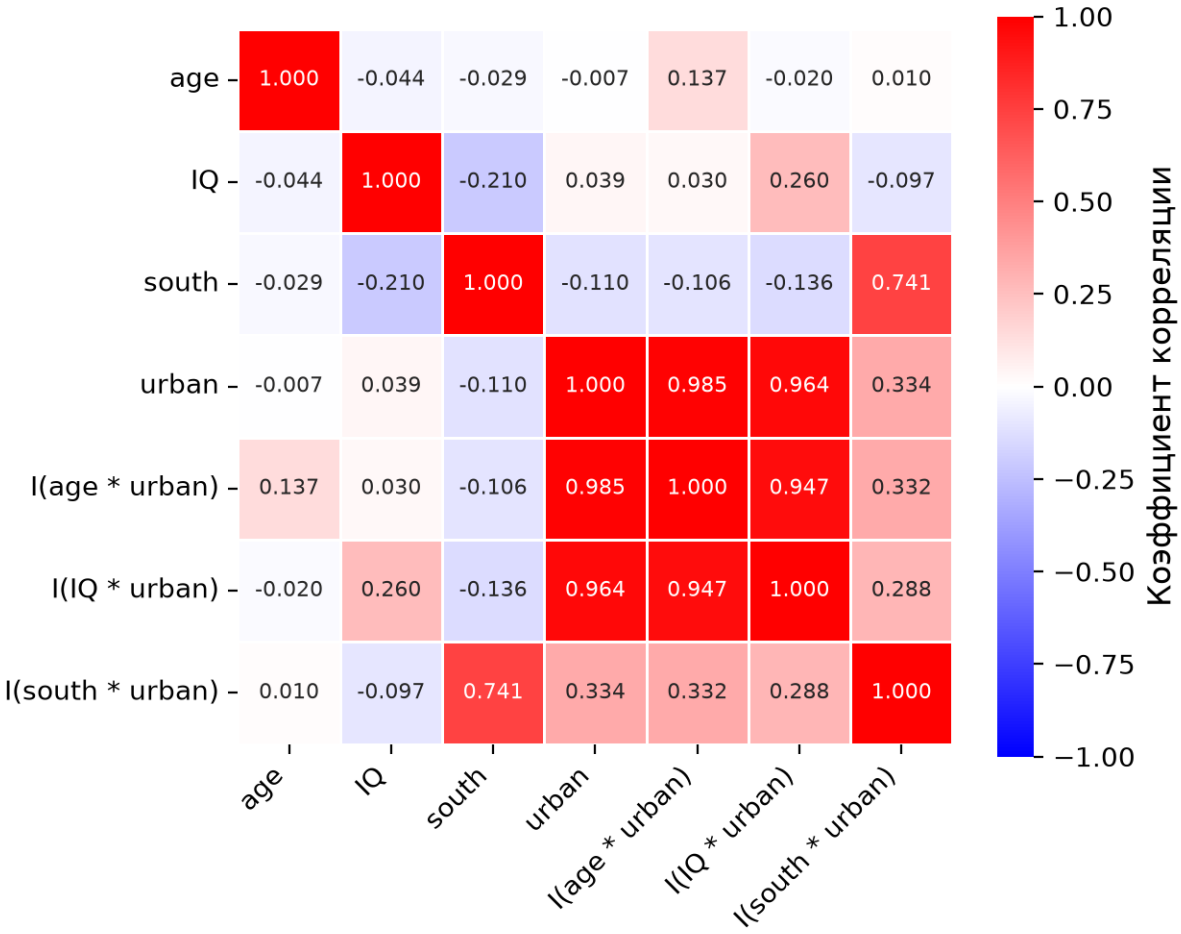


Рисунок 5: Корреляционная матрица регрессоров (wage equation #2)

! Условия теста

- уровень значимости: **1%**
- стандартные ошибки: **необастные**
- гипотеза 1: t-тест, значимость каждого коэффициента: $H_0 : \beta_j = 0$
- гипотеза 2: F-тест, значимость влияния места жительства (переменная `urban`): $H_0 : \beta_{urban} = \beta_{age \cdot urban} = \beta_{IQ \cdot urban} = \beta_{south \cdot urban} = 0$

Какие коэффициенты значимы?

Результаты t-теста для коэффициентов (необастные стандартные ошибки):

	Coef.	Std.Err.	t-value	p-value	Signif.
Intercept	4.999	0.312	16.016	<0.001	

	Coef.	Std.Err.	t-value	p-value	Signif.
age	0.024	0.007	3.294	0.001	***
IQ	0.008	0.002	5.116	<0.001	***
south	-0.014	0.052	-0.271	0.787	
urban	0.237	0.368	0.643	0.520	
I(age * urban)	-0.001	0.009	-0.069	0.945	
I(IQ * urban)	-1.41e-05	0.002	-0.007	0.994	
I(south * urban)	-0.117	0.061	-1.924	0.055	*

Signif. codes: $***$ $p < 0.01$, $**$ $p < 0.05$, $*$ $p < 0.1$

Коэффициенты, значимые на уровне 1% (по необастным стандартным ошибкам)

`age`, `IQ`

Проверим гипотезу о значимости влияния места жительства.

Результаты F-теста (необастные стандартные ошибки):

F	df1	df2	p-value
10.250	4	927	<0.001

Вычислите критическое значение. **Ответ округлите до 2-х десятичных знаков.**

Критическое значение

$F_{crit} = 3.34$

Какой можно сделать вывод?

Вывод

$F = 10.250 > 3.34$, гипотеза H_0 отвергается.
На первый взгляд противоречие: коэффициент при `urban` и все три коэффициента при взаимодействиях с `urban` по отдельности незначимы на уровне 1% (P-значения от 0.055 до 0.994), а гипотеза об их совместной незначимости отвергается. Оно объясняется мультиколлинеарностью: корреляции `urban` с `I(age * urban)` и `I(IQ * urban)` равны 0.985 и 0.964, VIF этих трёх регрессоров — 175.88, 114.32 и 53.14.