Задачи по Эконометрике-1: Гетероскедастичность

Н. В. Артамонов, А. Н. Лата (МГИМО МИД России)

Содержание

1 Диагностика модели: тесты на гетероскедастичность **1**
1.1 sleep equation . . . 1
1.2 wage equation . . . 2
1.3 output equation #1 . . . 3
1.4 cost equation #1 . . . 3
1.5 cost equation #2 . . . 4

2 Робастный t-тест (HC3) **5**
2.1 output equation #2 . . . 5
2.2 cost equation #3 . . . 6

3 Робастный F-тест **7**
3.1 output equation #3 . . . 7
3.2 cost equation #4 . . . 8

! Важно

- Логарифм натуральный; константа включается в модель по умолчанию.
- Данные лежат в папке `datasets`, описание переменных — в `datasets/data-description.md`.
- Ответы округляются до 2-х десятичных знаков, если в задаче не сказано иное; ответы считаются по неокруглённым оценкам.
- Коэффициенты подписаны как в statsmodels: `Intercept` — константа, `np.log(x)` — $\log x$, `I(x ** 2)` — x^2, `I(np.log(x) ** 2)` — $\log^2 x$.
- Тест Бройша–Пагана (BP-тест) — стьюдентизированная версия Коэнкера: статистика nR^2, функция `het_breuschpagan`.
- Робастные стандартные ошибки — HC3; P-значения и критические значения — по t- и F-распределениям: `fit(cov_type='HC3', use_t=True)`.

1 Диагностика модели: тесты на гетероскедастичность

1.1 sleep equation

Для набора данных `sleep75` рассмотрим регрессию

```
sleep ~ totwrk + age + I(age**2) + male + smsa + south
```

Здесь `sleep` — ночной сон и `totwrk` — работа (минут в неделю), `age` — возраст (лет), `male`, `smsa`, `south` — бинарные переменные.

! Условия теста

- уровень значимости: **5%**
- гипотеза: H_0: дисперсия ошибки не зависит от регрессоров модели (гомоскедастичность)
- тест Бройша–Пагана (BP-тест), стьюдентизированная версия Коэнкера: статистика nR^2, функция

`het_breuschpagan`

Проведите BP-тест на зависимость дисперсии от регрессоров модели.

Результат BP-теста:

BP	df	p-value
8.31	6	0.216

Модель была подогнана по 706 наблюдениям.

Вычислите необходимое критическое значение. **Ответ округлите до 2-х десятичных знаков.**

Критическое значение

$\chi^2_{crit}(6) = 12.59$

Какой можно сделать вывод?

Вывод

$BP = 8.31 < 12.59$ (тест Бройша–Пагана, версия Коэнкера), гипотеза H_0 не отвергается: тест указывает на гомоскедастичность.

1.2 wage equation

Для набора данных `wage1` рассмотрим регрессию

```
np.log(wage) ~ exper + I(exper**2) + female + married + smsa
```

Здесь `wage` — средняя почасовая заработная плата, `exper` — стаж (лет), `female`, `married`, `smsa` — бинарные переменные.

Условия теста

- уровень значимости: **5%**
- гипотеза: H_0: дисперсия ошибки не зависит от регрессоров модели (гомоскедастичность)
- тест Бройша–Пагана (BP-тест), стьюдентизированная версия Коэнкера: статистика nR^2, функция `het_breuschpagan`

Проведите BP-тест на зависимость дисперсии от регрессоров модели.

Результат BP-теста:

BP	df	p-value
8.94	5	0.111

Модель была подогнана по 526 наблюдениям.

Вычислите необходимое критическое значение. **Ответ округлите до 2-х десятичных знаков.**

Критическое значение

$\chi^2_{crit}(5) = 11.07$

Какой можно сделать вывод?

> **Вывод**
>
> $BP = 8.94 < 11.07$ (тест Бройша–Пагана, версия Коэнкера), гипотеза H_0 не отвергается: тест указывает на гомоскедастичность.

1.3 output equation #1

Для набора данных `Labour` рассмотрим регрессию

```
np.log(output) ~ np.log(capital) + np.log(labour) +
    I(np.log(capital)**2) + I(np.log(labour)**2)
```

Здесь `output` — добавленная стоимость и `capital` — основные фонды (млн евро), `labour` — число работников, `wage` — затраты на оплату труда на одного работника (тыс. евро).

> **Условия теста**
>
> - уровень значимости: **5%**
> - гипотеза: H_0: дисперсия ошибки не зависит от регрессоров модели (гомоскедастичность)
> - тест Бройша–Пагана (BP-тест), стьюдентизированная версия Коэнкера: статистика nR^2, функция `het_breuschpagan`

Проведите BP-тест на зависимость дисперсии от регрессоров модели.

Результат BP-теста:

BP	df	p-value
44.53	4	<0.001

Модель была подогнана по 569 наблюдениям.

Вычислите необходимое критическое значение. **Ответ округлите до 2-х десятичных знаков.**

> **Критическое значение**
>
> $\chi^2_{crit}(4) = 9.49$

Какой можно сделать вывод?

> **Вывод**
>
> $BP = 44.53 > 9.49$ (тест Бройша–Пагана, версия Коэнкера), гипотеза H_0 отвергается: тест указывает на гетероскедастичность.

1.4 cost equation #1

Для набора данных `Electricity` рассмотрим регрессию

```
np.log(cost) ~ np.log(q) + I(np.log(q)**2) +
    np.log(pf) + np.log(pl) + np.log(pk)
```

Здесь `cost` — общие издержки, `q` — выпуск, `pf` — цена топлива, `pl` — ставка заработной платы, `pk` — индекс цены капитала.

! Условия теста

- уровень значимости: **5%**
- гипотеза: H_0: дисперсия ошибки не зависит от регрессоров модели (гомоскедастичность)
- тест Бройша–Пагана (BP-тест), стьюдентизированная версия Коэнкера: статистика nR^2, функция `het_breuschpagan`

Проведите BP-тест на зависимость дисперсии от регрессоров модели.

Результат BP-теста:

BP	df	p-value
45.08	5	<0.001

Модель была подогнана по 158 наблюдениям.

Вычислите необходимое критическое значение. **Ответ округлите до 2-х десятичных знаков.**

i Критическое значение

$\chi^2_{crit}(5) = 11.07$

Какой можно сделать вывод?

Вывод

$BP = 45.08 > 11.07$ (тест Бройша–Пагана, версия Коэнкера), гипотеза H_0 отвергается: тест указывает на гетероскедастичность.

1.5 cost equation #2

Для набора данных `Electricity` рассмотрим регрессию

```
np.log(cost) ~ np.log(q) + I(np.log(q)**2) +
    np.log(pf) + np.log(pl) + np.log(pk) +
    I(np.log(pf)**2) + I(np.log(pl)**2) + I(np.log(pk)**2)
```

! Условия теста

- уровень значимости: **5%**
- гипотеза: H_0: дисперсия ошибки не зависит от регрессоров модели (гомоскедастичность)
- тест Бройша–Пагана (BP-тест), стьюдентизированная версия Коэнкера: статистика nR^2, функция `het_breuschpagan`

Проведите BP-тест на зависимость дисперсии от регрессоров модели.

Результат BP-теста:

BP	df	p-value
49.30	8	<0.001

Модель была подогнана по 158 наблюдениям.

Вычислите необходимое критическое значение. **Ответ округлите до 2-х десятичных знаков.**

Критическое значение

$\chi^2_{crit}(8) = 15.51$

Какой можно сделать вывод?

Вывод

$BP = 49.30 > 15.51$ (тест Бройша–Пагана, версия Коэнкера), гипотеза H_0 отвергается: тест указывает на гетероскедастичность.

2 Робастный t-тест (HC3)

2.1 output equation #2

Для набора данных `Labour` рассмотрим регрессию

```
np.log(output) ~ np.log(capital) + np.log(labour) +
    I(np.log(capital)**2) + I(np.log(labour)**2)
```

Результаты t-теста для коэффициентов (необастные стандартные ошибки):

	Coef.	Std.Err.	t-value	p-value	Signif.
Intercept	-1.3039	0.1886	-6.9141	<0.001	
np.log(capital)	0.1831	0.0166	11.0549	<0.001	***
np.log(labour)	0.5153	0.0834	6.1814	<0.001	***
I(np.log(capital) ** 2)	0.0227	0.0050	4.5181	<0.001	***
I(np.log(labour) ** 2)	0.0203	0.0096	2.1116	0.0352	**

Signif. codes: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$

Результаты t-теста для коэффициентов (робастные стандартные ошибки, HC3):

	Coef.	Std.Err.	t-value	p-value	Signif.
Intercept	-1.3039	0.4933	-2.6435	0.0084	
np.log(capital)	0.1831	0.0295	6.2148	<0.001	***
np.log(labour)	0.5153	0.2064	2.4966	0.0128	**
I(np.log(capital) ** 2)	0.0227	0.0083	2.7375	0.0064	***
I(np.log(labour) ** 2)	0.0203	0.0210	0.9654	0.3348	

Signif. codes: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$

Модель была подогнана по 569 наблюдениям.

Условия теста

- уровень значимости: **5%**
- стандартные ошибки: **необастные и робастные HC3**
- гипотеза: $H_0 : \beta_j = 0$ — для каждого коэффициента отдельно

Какие коэффициенты значимы?

ℹ Коэффициенты, значимые на уровне 5% (по необастным стандартным ошибкам)

```
np.log(capital), np.log(labour), I(np.log(capital) ** 2), I(np.log(labour) ** 2)
```

ℹ Коэффициенты, значимые на уровне 5% (по робастным стандартным ошибкам HC3)

```
np.log(capital), np.log(labour), I(np.log(capital) ** 2)
```

2.2 cost equation #3

Для набора данных `Electricity` рассмотрим регрессию

```
np.log(cost) ~ np.log(q) + I(np.log(q)**2) +
    np.log(pf) + np.log(pl) + np.log(pk)
```

Результаты t-теста для коэффициентов (необастные стандартные ошибки):

	Coef.	Std.Err.	t-value	p-value	Signif.
Intercept	-6.7387	0.7063	-9.5412	<0.001	
np.log(q)	0.4030	0.0316	12.7343	<0.001	***
I(np.log(q) ** 2)	0.0304	0.0022	14.0236	<0.001	***
np.log(pf)	0.6847	0.0427	16.0430	<0.001	***
np.log(pl)	0.1461	0.0705	2.0729	0.0399	**
np.log(pk)	0.1571	0.0577	2.7214	0.0073	***

Signif. codes: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$

Результаты t-теста для коэффициентов (робастные стандартные ошибки, HC3):

	Coef.	Std.Err.	t-value	p-value	Signif.
Intercept	-6.7387	0.8472	-7.9538	<0.001	
np.log(q)	0.4030	0.0662	6.0855	<0.001	***
I(np.log(q) ** 2)	0.0304	0.0041	7.4194	<0.001	***
np.log(pf)	0.6847	0.0519	13.1882	<0.001	***
np.log(pl)	0.1461	0.0854	1.7114	0.0891	*
np.log(pk)	0.1571	0.0623	2.5216	0.0127	**

Signif. codes: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$

Модель была подогнана по 158 наблюдениям.

❗ Условия теста

- уровень значимости: **5%**
- стандартные ошибки: **необастные и робастные HC3**
- гипотеза: $H_0 : \beta_j = 0$ — для каждого коэффициента отдельно

Какие коэффициенты значимы?

ℹ Коэффициенты, значимые на уровне 5% (по необастным стандартным ошибкам)

```
np.log(q), I(np.log(q) ** 2), np.log(pf), np.log(pl), np.log(pk)
```

ℹ Коэффициенты, значимые на уровне 5% (по робастным стандартным ошибкам HC3)

```
np.log(q), I(np.log(q) ** 2), np.log(pf), np.log(pk)
```

3 Робастный F-тест

3.1 output equation #3

Для набора данных `Labour` рассмотрим регрессию

```
np.log(output) ~ np.log(capital) + np.log(labour) + np.log(wage) +
    I(np.log(capital)**2) + I(np.log(labour)**2) + I(np.log(wage)**2)
```

Результаты t-теста для коэффициентов (робастные стандартные ошибки, HC3):

	Coef.	Std.Err.	t-value	p-value	Signif.
Intercept	-3.5683	1.6513	-2.1609	0.0311	
np.log(capital)	0.1404	0.0297	4.7196	<0.001	***
np.log(labour)	0.4716	0.1975	2.3872	0.0173	**
np.log(wage)	0.4762	0.8952	0.5320	0.5949	
I(np.log(capital) ** 2)	0.0071	0.0085	0.8314	0.4061	
I(np.log(labour) ** 2)	0.0275	0.0200	1.3765	0.1692	
I(np.log(wage) ** 2)	0.0516	0.1257	0.4103	0.6818	

Signif. codes: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$

Модель была подогнана по 569 наблюдениям.

❗ Условия теста

- уровень значимости: **5%**
- стандартные ошибки: **робастные, HC3**
- гипотеза: $H_0 : \beta_{\log^2(capital)} = \beta_{\log^2(labour)} = \beta_{\log^2(wage)} = 0$

Проверим гипотезу о значимости влияния квадратов переменных.

Результаты F-теста (неробастные стандартные ошибки):

F	df1	df2	p-value
13.30	3	562	<0.001

Результаты F-теста (робастные стандартные ошибки, HC3):

F	df1	df2	p-value
2.06	3	562	0.104

Какое критическое значение? **Ответ округлите до 2-х десятичных знаков.**

ℹ Критическое значение

$F_{crit}(3, 562) = 2.62$

Значимо ли влияние квадратов переменных?

Вывод

$F = 2.06 < 2.62$ (робастный F-тест, HC3), гипотеза H_0 не отвергается: влияние незначимо. По неробастному F-тесту ($F = 13.30 > 2.62$) гипотеза отвергается — вывод меняется.

3.2 cost equation #4

Для набора данных `Electricity` рассмотрим регрессию

```
np.log(cost) ~ np.log(q) + I(np.log(q)**2) +
    np.log(pf) + np.log(pl) + np.log(pk) +
    I(np.log(pf)**2) + I(np.log(pl)**2) + I(np.log(pk)**2)
```

Результаты t-теста для коэффициентов (неробастные стандартные ошибки):

	Coef.	Std.Err.	t-value	p-value	Signif.
Intercept	-44.4035	23.4317	-1.8950	0.0600	
np.log(q)	0.3963	0.0321	12.3329	<0.001	***
I(np.log(q) ** 2)	0.0309	0.0022	14.0201	<0.001	***
np.log(pf)	0.8988	0.6161	1.4588	0.1467	
np.log(pl)	8.3334	5.3296	1.5636	0.1200	
np.log(pk)	0.4362	1.5224	0.2865	0.7749	
I(np.log(pf) ** 2)	-0.0305	0.0927	-0.3290	0.7426	
I(np.log(pl) ** 2)	-0.4554	0.2967	-1.5350	0.1269	
I(np.log(pk) ** 2)	-0.0360	0.1875	-0.1923	0.8478	

Signif. codes: $***\ p < 0.01$, $**\ p < 0.05$, $*\ p < 0.1$

Результаты t-теста для коэффициентов (робастные стандартные ошибки, HC3):

	Coef.	Std.Err.	t-value	p-value	Signif.
Intercept	-44.4035	32.7823	-1.3545	0.1776	
np.log(q)	0.3963	0.0664	5.9670	<0.001	***
I(np.log(q) ** 2)	0.0309	0.0041	7.5071	<0.001	***
np.log(pf)	0.8988	1.8426	0.4878	0.6264	
np.log(pl)	8.3334	7.5069	1.1101	0.2687	
np.log(pk)	0.4362	1.6217	0.2690	0.7883	
I(np.log(pf) ** 2)	-0.0305	0.2695	-0.1132	0.9100	
I(np.log(pl) ** 2)	-0.4554	0.4173	-1.0915	0.2768	
I(np.log(pk) ** 2)	-0.0360	0.2003	-0.1799	0.8575	

Signif. codes: $***\ p < 0.01$, $**\ p < 0.05$, $*\ p < 0.1$

Модель была подогнана по 158 наблюдениям.

Условия теста

- уровень значимости: **5%**
- стандартные ошибки: **робастные, HC3**
- гипотеза 1: значимость влияния `pl`, $H_0 : \beta_{\log(pl)} = \beta_{\log^2(pl)} = 0$
- гипотеза 2: значимость влияния `pk`, $H_0 : \beta_{\log(pk)} = \beta_{\log^2(pk)} = 0$
- гипотеза 3: значимость влияния `pf`, $H_0 : \beta_{\log(pf)} = \beta_{\log^2(pf)} = 0$

Гипотеза 1: значимость влияния pl

Проверим гипотезу о значимости влияния `pl`.

Результаты F-теста (необастные стандартные ошибки):

F	df1	df2	p-value
3.48	2	149	0.033

Результаты F-теста (робастные стандартные ошибки, HC3):

F	df1	df2	p-value
1.98	2	149	0.142

Гипотеза 2: значимость влияния pk

Проверим гипотезу о значимости влияния `pk`.

Результаты F-теста (необастные стандартные ошибки):

F	df1	df2	p-value
2.98	2	149	0.054

Результаты F-теста (робастные стандартные ошибки, HC3):

F	df1	df2	p-value
2.21	2	149	0.113

Гипотеза 3: значимость влияния pf

Проверим гипотезу о значимости влияния `pf`.

Результаты F-теста (необастные стандартные ошибки):

F	df1	df2	p-value
129.37	2	149	<0.001

Результаты F-теста (робастные стандартные ошибки, HC3):

F	df1	df2	p-value
79.13	2	149	<0.001

Какое критическое значение (оно общее для трёх гипотез)? **Ответ округлите до 2-х десятичных знаков.**

> **i** Критическое значение
>
> $F_{crit}(2, 149) = 3.06$

Значимо ли влияние в каждой из трёх гипотез?

Вывод

- Гипотеза 1 (`pl`): $F = 1.98 < 3.06$ (робастный F-тест, HC3), гипотеза H_0 не отвергается: влияние незначимо. По неробастному F-тесту ($F = 3.48 > 3.06$) гипотеза отвергается — вывод меняется.
- Гипотеза 2 (`pk`): $F = 2.21 < 3.06$ (робастный F-тест, HC3), гипотеза H_0 не отвергается: влияние незначимо. Неробастный F-тест даёт тот же вывод ($F = 2.98 < 3.06$).
- Гипотеза 3 (`pf`): $F = 79.13 > 3.06$ (робастный F-тест, HC3), гипотеза H_0 отвергается: влияние значимо. Неробастный F-тест даёт тот же вывод ($F = 129.37 > 3.06$).